

Detecção e classificação de lesões mamárias benignas e malignas em ultrassonografia por meio de YOLO11

Juan José Gouvêa Cardenas¹
Felipe Ramirez Pereira Botero²

¹Juno Woz Labs, Manaus, Amazonas, Brasil

²Universidade do Estado do Amazonas (UEA), Manaus, Amazonas, Brasil

Correspondência: inbox@junowoz.com, frpbotero@gmail.com

11 de junho de 2026

Resumo

Resumo. O câncer de mama é a neoplasia mais incidente entre mulheres no Brasil, e o diagnóstico tardio, agravado pela escassez de radiologistas na rede pública, contribui para a mortalidade. A ultrassonografia é uma modalidade complementar relevante, sobretudo em mamas densas, e sistemas de auxílio computacional ao diagnóstico (*Computer-Aided Diagnosis*, CAD) podem apoiar a leitura dos exames. Este trabalho investiga o detector de objetos *YOLO11s* para *localizar* (caixa delimitadora) e *classificar* (benigna/maligna) lesões mamárias em imagens de ultrassom do conjunto público BUSI. Diferentemente de boa parte da literatura sobre o BUSI, que avalia a tarefa como classificação por imagem e reporta métricas potencialmente infladas, adota-se um protocolo de avaliação adequado a detectores: deduplicação por *hash* antes da divisão dos dados, divisão estratificada treino/validação/teste (70/15/15) com semente fixa e conjunto de teste cego, e avaliação por `model.val()` com casamento por interseção sobre união (IoU), reportando mAP@50, mAP@50–95 e precisão/revocação/F1 por classe, além da taxa de falsos positivos em imagens normais. No conjunto de teste cego, o modelo alcançou mAP@50 de 0,709 e mAP@50–95 de 0,438; por classe, a benigna (AP@50 0,785) superou a maligna (AP@50 0,633), com revocação de 0,516 na classe maligno. Os resultados são interpretados contra a faixa realista de *detecção* em BUSI puro, e não contra índices de *classificação* de conjuntos aumentados, que não são comparáveis. As limitações do estudo (defeitos do BUSI, origem monocêntrica, ausência de divisão por paciente e de validação externa) são discutidas.

Palavras-chave: visão computacional; redes neurais convolucionais; YOLO; ultrassonografia mamária; detecção de objetos; auxílio ao diagnóstico (CAD).

Abstract. Breast cancer is the most frequent malignancy among women in Brazil, and late diagnosis, worsened by the shortage of radiologists in the public health system, contributes to mortality. Ultrasound is a relevant complementary modality, especially for dense breasts, and Computer-Aided Diagnosis (CAD) systems may support image reading. This work investigates the *YOLO11s* object detector to *localize* (bounding box) and *classify* (benign/malignant) breast lesions in ultrasound images from the public BUSI dataset. Unlike much of the BUSI literature, which evaluates the task as per-image classification and reports potentially inflated metrics, we adopt a detection-appropriate protocol: content-hash deduplication before splitting, stratified train/validation/test split (70/15/15) with a fixed seed and a blind test set, and `model.val()` evaluation with IoU matching, reporting mAP@50, mAP@50–95 and per-class precision/recall/F1, plus the false-positive rate on normal images. On the blind test set, the model reached mAP@50 of 0.709 and mAP@50–95 of 0.438.

Keywords: computer vision; convolutional neural networks; YOLO; breast ultrasound; object detection; computer-aided diagnosis.

1 Introdução

O câncer de mama é o tipo de câncer mais incidente entre mulheres no Brasil (excetuando-se os de pele não melanoma). Para o triênio 2023–2025, o Instituto Nacional de Câncer (INCA) estimou cerca de 73.610 casos novos por ano, com taxa bruta de aproximadamente 66,54 casos por 100 mil mulheres (INCA, 2022). A doença é também a principal causa de morte oncológica feminina no país (INCA, 2024).

O diagnóstico precoce é determinante para o prognóstico, mas o acesso oportuno permanece desigual. Estudos brasileiros relatam mediana de cerca de 70 dias entre a suspeita e o diagnóstico, com tempos maiores no Sistema Único de Saúde (SUS) do que na rede privada (Campos et al., 2022). Esse cenário é agravado pela distribuição irregular de mamógrafos e pela escassez de radiologistas, limitando a triagem por imagem em larga escala (INCA, 2024).

Nesse contexto, a visão computacional oferece ferramentas de apoio à leitura de exames. A *ultrassonografia* é uma modalidade complementar importante: em mamas densas, a sensibilidade da mamografia isolada é reduzida, e a combinação com ultrassom aumenta a detecção. Sistemas de IA já vêm sendo avaliados como *segundo leitor* em rastreamento mamográfico, com evidência de segurança como apoio (não substituto) (Lång et al., 2023). Detectores de objetos da família YOLO (*You Only Look Once*), introduzidos por Redmon et al. (2016), destacam-se pela inferência em uma única passagem, conciliando precisão e velocidade, propriedades atraentes para sistemas de apoio.

É essencial delimitar o escopo com rigor. Um modelo de imagem *não diagnóstica câncer*: ele localiza uma lesão (uma caixa delimitadora) e lhe atribui um rótulo de aparência (benigna ou maligna) com um grau de confiança. O diagnóstico definitivo exige correlação clínica e confirmação histopatológica (biópsia). Portanto, este trabalho posiciona-se como um sistema de *detecção e classificação* de lesões e de *auxílio ao diagnóstico* (CAD), cujas saídas devem ser interpretadas como “sugestivas de”, em referência ao léxico BI-RADS, e nunca como veredito clínico (Seção 8). A padronização de laudos por BI-RADS contribui para reduzir a variabilidade interobservador (Pires et al., 2004).

Objetivo. Desenvolver e avaliar, de forma metodologicamente rigorosa, um detector YOLO para localização e classificação de lesões mamárias benignas e malignas em ultrassonografia, sobre o conjunto público BUSI.

Contribuições. (i) um *pipeline* reproduzível de conversão de máscaras de segmentação em rótulos de detecção, com semente fixa e divisão estratificada cega; (ii) o tratamento das imagens normais como exemplos negativos (fundo), permitindo *quantificar falsos positivos*; (iii) um protocolo de avaliação *adequado a detectores* (casamento por IoU e métricas por classe via `model.val()`), em substituição à prática inadequada de avaliar a detecção como classificação por imagem; e (iv) a mitigação e a *discussão explícita* do vazamento de dados documentado no BUSI.

2 Trabalhos Relacionados

A detecção automática de lesões em ultrassom mamário é um passo clássico de sistemas CAD. Yap et al. (2018) avaliaram abordagens de aprendizado profundo para a detecção de lesões em ultrassom (incluindo uma rede totalmente convolucional por transferência de aprendizado), estabelecendo um marco metodológico e apontando a ausência de um conjunto comum como obstáculo à comparação entre métodos, lacuna que o BUSI (Al-Dhabyani et al., 2020) ajudaria a preencher.

Tabela 1: Trabalhos de detecção/classificação por aprendizado profundo em imagem de mama. Note-se a diferença de *modalidade* (mamografia *vs.* ultrassom) e de *tarefa* (detecção *vs.* classificação); resultados sobre conjuntos aumentados ou combinados não são diretamente comparáveis a um *split* BUSI-*only* deduplicado.

Trabalho	Modalidade	Tarefa	Resultado-chave reportado
Yap et al. (2018)	Ultrassom	Detecção	Marco de detecção (CNN); sem conjunto comum à época
Wurzel e Martins (2022)	Mamografia (CBIS-DDSM)	Classificação	Acurácia $\approx$ 91,3% (CNN-VGG)
Anas et al. (2024)	Mamografia (INbreast)	Det.+Class.	MCC 92%; acurácia até 98%
Prinzi et al. (2024)	Mamografia (INbreast)	Detecção	mAP 0,835 $\pm$ 0,098 (5-fold, +TL)
Mohammed e Ekmekci (2024)	Mamografia (CBIS-DDSM)	Detecção	mAP@50 91,15% (+CLAHE)
Jabeen et al. (2022)	Ultrassom (BUSI aum.)	Classificação	Acurácia 99,18% (<i>aumentado</i>)
Este trabalho	Ultrassom (BUSI dedup.)	Detecção	mAP@50 0,709; mAP@50–95 0,438

Em **mamografia**, há evidência consistente de viabilidade da família YOLO: Prinzi et al. (2024) usaram YOLOv5s com transferência de aprendizado e validação cruzada (mAP $\approx$ 0,835); Anas et al. (2024) combinaram YOLOv5 com Mask R-CNN reportando MCC de 92% e acurácia de até 98% no INbreast; e Mohammed e Ekmekci (2024) propuseram um YOLO multiescala (mAP@50 de 91,15%) com pré-processamento por CLAHE. No Brasil, Wurzel e Martins (2022) avaliaram redes convolucionais (VGG) para classificação em mamografia (CBIS-DDSM), com acurácia em torno de 91,3%. Esses trabalhos apoiam transferência de aprendizado e validação cruzada, mas em *modalidade distinta* (mamografia).

Cuidado com métricas não comparáveis. Parte da literatura sobre o BUSI reporta acurácias muito altas (94–99%) ao tratar a tarefa como *classificação por imagem* e/ou ao treinar sobre dados fortemente aumentados ou combinados. Por exemplo, Jabeen et al. (2022) reportam acurácia superior a 99% sobre dados aumentados. Tais números medem uma tarefa diferente (rótulo único por imagem, sem localização), frequentemente sobre conjuntos não comparáveis ao BUSI puro, e não devem servir de linha de base para *detecção*. A Tabela 1 sintetiza essas diferenças de modalidade e de tarefa.

Evolução das arquiteturas YOLO. O YOLO11 (Jocher e Qiu, 2024; Khanam e Hussain, 2024) introduz os blocos *C3k2* (em substituição ao *C2f*) e *C2PSA* (atenção espacial após o *SPPF*), com bom equilíbrio entre custo e desempenho, sendo a versão estável recomendada para uso prático. Versões posteriores, como o YOLOv12 (Tian et al., 2025), enfatizam mecanismos de atenção mas podem apresentar instabilidade de treino em conjuntos pequenos; o YOLO26 (Ultralytics, 2026), com inferência sem supressão não máxima (NMS), é citado como direção futura. Optou-se pelo YOLO11s por estabilidade e reprodutibilidade em um conjunto de poucas centenas de imagens.

3 Materiais e Métodos

3.1 Conjunto de dados: BUSI

Utiliza-se o *Breast Ultrasound Images Dataset* (BUSI), publicado por Al-Dhabyani et al. (2020)¹. O BUSI reúne 780 imagens de ultrassom de mama, em formato PNG e resolução média próxima de 500×500 px, coletadas em 2018 de 600 pacientes do sexo feminino (25–75 anos) em um único centro (Baheya Hospital, Cairo, Egito), com equipamento LOGIQ E9. As imagens distribuem-se em três classes (*normal*, *benigna* e *maligna*) e acompanham *máscaras de segmentação* de referência para os casos com lesão, recurso raro entre bases públicas de ultrassom mamário e que viabiliza a tarefa de detecção. Na cópia distribuída (Kaggle), a contagem é de 437 imagens benignas, 210 malignas e 133 normais (total 780); registra-se que o artigo original menciona 487 benignas, divergência atribuível à curadoria da distribuição.

3.2 Qualidade dos dados e mitigação de vazamento

O BUSI possui defeitos documentados. Pawlowska et al. (2023) reportam cerca de 155 imagens duplicadas ($\approx 19\%$), além de imagens com marcadores de medição, texto, Doppler colorido e até estruturas não mamárias; análises subsequentes indicam que *mais de 40%* das imagens apresentam algum problema significativo (Pawlowska et al., 2024), e que duplicatas distribuídas entre treino e validação produzem *vazamento de dados* (*data leakage*), inflando métricas. Como o BUSI *não* fornece identificadores de paciente, é impossível garantir divisão por paciente.

Aplica-se, portanto, **deduplicação por hash de conteúdo (MD5)** antes de qualquer divisão, mantendo a primeira ocorrência de cada imagem; foi removida 1 imagem idêntica, resultando em 779 imagens (composição na Tabela 3). Ressalva-se que parte das duplicatas documentadas no BUSI são *near-duplicates* (mesma lesão com leve reprocessamento), não capturadas por *hash* exato; essa redundância residual, somada à ausência de IDs de paciente, constitui limitação declarada na Seção 6. Ainda assim, em comparação com trabalhos que treinam e avaliam sobre o BUSI *bruto*, a deduplicação exata e o conjunto de teste cego reduzem o risco de superestimação por imagens idênticas entre os conjuntos.

3.3 Geração de rótulos de detecção

Para cada lesão (uma caixa por máscara, contemplando os casos multilesão do BUSI), a máscara binária é convertida em caixa delimitadora: localizam-se os *pixels* não nulos, calcula-se o retângulo envolvente (x, y, w, h) e normalizam-se as coordenadas para o formato YOLO,

$$x_c = \frac{x + w/2}{W}, \quad y_c = \frac{y + h/2}{H}, \quad w_n = \frac{w}{W}, \quad h_n = \frac{h}{H},$$

onde W e H são as dimensões da imagem. Definem-se duas classes de detecção: **0 = benigno** e **1 = maligno**. As imagens *normais* não recebem caixas: tornam-se *exemplos negativos* (fundo), para os quais a saída esperada é a ausência de detecção.

3.4 Divisão dos dados e aumento

Após a deduplicação, os dados são divididos de forma *estratificada por classe* em treino (70%), validação (15%) e teste (15%), com semente fixa (**SEED = 42**) e conjunto de teste mantido cego até a avaliação final. A divisão ocorre *antes* da geração de rótulos e de qualquer aumento de

¹Publicado em *Data in Brief*, v. 28, art. 104863, fev. 2020 (recebido/*online* em nov. 2019). Adota-se **2020** como ano de referência.

Tabela 2: Configuração de treino (Kaggle, GPU NVIDIA Tesla T4).

Parâmetro	Valor
Modelo base	yolo11s.pt (pré-treinado em COCO)
Resolução (imgsz)	640
Épocas (máx.)	100 (parada antecipada na época 82)
<i>Early stopping</i> (patience)	25
Batch	16
Otimizador	auto $\rightarrow$ AdamW (lr0 $\approx$ 0,0017)
Aumento	rotação $\leq 10^\circ$; <i>flip</i> horizontal ($p=0,5$); <i>translate</i> 0,1; <i>scale</i> 0,3; sem <i>shear</i> /perspectiva
Semente	42 (fixa)
Framework	Ultralytics 8.4.66; PyTorch 2.10.0 (CUDA)

dados. As imagens normais entram em todos os subconjuntos como negativos, permitindo medir a taxa de falsos positivos (Seção 3.6). O aumento de dados é aplicado *apenas ao treino e em tempo de execução*. Adota-se aumento *conservador*, coerente com a anatomia do ultrassom: rotações leves ($\leq 10^\circ$), espelhamento horizontal, pequenos deslocamentos e escala; desabilitam-se cisalhamento, perspectiva e espelhamento vertical, que introduzem distorções geométricas pouco plausíveis na modalidade.

3.5 Arquitetura e configuração de treino

Adota-se o **YOLO11s** (Jocher e Qiu, 2024) com pesos pré-treinados em COCO (*transferência de aprendizado*), prática consolidada para imagem médica com dados escassos (Prinzi et al., 2024). Por se tratar de poucas centenas de imagens, variantes grandes tendem ao *overfitting*; a variante *small* equilibra precisão e custo. A Tabela 2 resume os hiperparâmetros. O otimizador foi selecionado automaticamente pelo Ultralytics (`optimizer=auto`), resultando em AdamW com taxa de aprendizado inicial $\approx 0,0017$. Com *early stopping* (`patience = 25`), o treino encerrou na época 82, com o melhor modelo observado na época 57.

3.6 Protocolo de avaliação

A detecção é avaliada com *casamento por IoU* entre caixas preditas e de referência: uma predição é verdadeiro-positivo (VP) quando sua sobreposição (*Intersection over Union*) com a verdade excede um limiar (tipicamente 0,5); caixas excedentes ou mal localizadas são falsos-positivos (FP) e lesões não detectadas são falsos-negativos (FN). A avaliação usa `model.val()` (Ultralytics) sobre o conjunto de teste cego, reportando-se:

- **Globais:** mAP@50 e mAP@50–95 (média sobre IoU de 0,50 a 0,95), além de precisão e revocação médias;
- **Por classe:** precisão, revocação, AP@50, AP@50–95 e $F1 = 2PR/(P + R)$ para benigno e maligno;
- **Matriz de confusão** (incluindo *background*) para inspecionar FP/FN;
- **Taxa de falsos positivos nas imagens normais**, medindo quantos negativos geram detecção espúria.

A revocação equivale à *sensibilidade* ($VP/(VP + FN)$) e deve ser priorizada na triagem oncológica, em que o custo de um falso-negativo é elevado. A especificidade clássica não é diretamente definível em detecção (não há “verdadeiro-negativo” bem definido por caixa); por isso a robustez a FP é avaliada sobre as imagens normais.

Por que a avaliação por classificação por imagem é inadequada. Uma prática comum, e que evitamos, consiste em tomar, para cada imagem, a classe da *primeira* caixa detectada como “predição da imagem” e gerar um `classification_report`. Esse procedimento *ignora a localização* (uma caixa com a classe certa, porém em posição errada, conta como acerto), descarta múltiplos objetos e não contabiliza corretamente FP/FN.

3.7 Reprodutibilidade

Toda operação aleatória usa semente fixa (42). O ambiente de execução foi Kaggle com GPU NVIDIA Tesla T4, Ultralytics 8.4.66, PyTorch 2.10.0 e Python 3.12.13. Código, notebook e instruções estão no repositório público (Seção 8).

4 Resultados

4.1 Composição dos conjuntos após deduplicação

A Tabela 3 apresenta a composição dos conjuntos após a remoção da duplicata exata (779 imagens) e a divisão estratificada.

Tabela 3: Composição dos conjuntos após deduplicação e divisão estratificada (70/15/15). Imagens normais (sem lesão) entram como exemplos negativos.

Conjunto	Benigno	Maligno	Normal	Total
Treino	306	146	93	545
Validação	65	32	20	117
Teste	66	31	20	117
Total	437	209	133	779

4.2 Métricas de detecção no conjunto de teste

A Tabela 4 apresenta as métricas no conjunto de teste cego. O modelo alcançou **mAP@50 de 0,709** e **mAP@50–95 de 0,438**. A classe benigna foi mais bem detectada (AP@50 0,785; revocação 0,772) do que a maligna (AP@50 0,633; revocação 0,516). A Figura 1 mostra as curvas *precision–recall* por classe, e a Figura 2 a evolução das perdas e métricas ao longo do treino.

Tabela 4: Métricas de detecção no conjunto de teste cego (BUSI deduplicado), obtidas via `model.val()` com casamento por IoU.

Classe	Precisão	Revocação	F1	AP@50	AP@50–95
Benigno	0,666	0,772	0,715	0,785	0,530
Maligno	0,618	0,516	0,562	0,633	0,347
Global (m)	0,642	0,644	0,639	0,709	0,438




Figura 1: Curva *precision-recall* por classe no conjunto de teste (AP@50: benigno 0,785; maligno 0,633; média 0,709).




Figura 2: Evolução do treino (perdas de *box*, classificação e DFL) e das métricas de validação (precisão, revocação, mAP@50 e mAP@50–95) ao longo das épocas. A parada antecipada ocorreu na época 82 (melhor modelo na época 57).

4.3 Falsos positivos e matriz de confusão

Das 20 imagens normais do conjunto de teste, 3 (15,0%) geraram ao menos uma detecção espúria. A matriz de confusão normalizada (Figura 3) detalha o comportamento por classe: cerca de 76% das instâncias benignas e 55% das malignas foram corretamente atribuídas. Observa-se que aproximadamente 26% das lesões malignas foram rotuladas como benignas e uma parcela adicional não foi detectada (atribuída a fundo). A confusão maligno→benigno é a de maior consequência clínica.




Figura 3: Matriz de confusão normalizada no conjunto de teste (classes benigno, maligno e *background*). A coluna *background* representa as detecções espúrias sobre regiões/imagens sem lesão.

4.4 Análise qualitativa

A Figura 4 ilustra detecções representativas no conjunto de teste: uma lesão benigna e uma maligna corretamente localizadas e rotuladas, e uma imagem normal sem detecção (resultado esperado para um exemplo negativo).




Figura 4: Exemplos qualitativos de detecção no conjunto de teste. (a) lesão benigna (confiança 0,80); (b) lesão maligna (confiança 0,84); (c) imagem normal, sem detecção. As caixas e os rótulos são gerados pelo modelo.

5 Discussão

O modelo alcançou mAP@50 de 0,709 e mAP@50–95 de 0,438 no conjunto de teste cego. Esse desempenho deve ser interpretado contra a *faixa realista* de detecção sobre o BUSI-*only* e contra os trabalhos de YOLO em mama (Seção 2), e *não* contra os índices de 94–99% de *classificação* (tarefa distinta) ou sobre conjuntos aumentados/combinados, que não são comparáveis. Trata-se de um resultado modesto, porém honesto: a deduplicação prévia e o teste cego eliminam parte da superestimação típica de *pipelines* treinados e avaliados sobre o BUSI bruto.

A análise por classe confirma a expectativa: a classe benigna (AP@50 0,785; revocação 0,772)

supera a maligna (AP@50 0,633; revocação 0,516). A menor revocação na classe *maligna*, a mais crítica clinicamente, reflete o menor número de exemplos de treino (146 *vs.* 306 benignos) e a maior heterogeneidade das lesões malignas. A matriz de confusão (Figura 3) mostra que cerca de 26% das lesões malignas foram confundidas com benignas; essa confusão maligno→benigno (falsa tranquilização) é o erro de maior consequência clínica e reforça que o sistema é uma prova de conceito, não uma ferramenta de triagem. A taxa de falsos positivos nas imagens normais (15%) indica que a maioria dos casos sem lesão não gera alarme, embora a propensão a falsos positivos não seja desprezível, ponto relevante em triagem: ganhos de sensibilidade acompanhados de excesso de alarmes implicam encaminhamentos e biópsias desnecessárias.

Em síntese, os resultados sustentam a *viabilidade* da abordagem de detecção como prova de conceito, ao mesmo tempo em que evidenciam, com transparência, suas fragilidades, sobretudo a sensibilidade ainda limitada na classe maligna, o que é preferível a índices elevados, porém contaminados por vazamento.

6 Limitações

- **Redundância residual do conjunto.** A deduplicação exata removeu apenas 1 imagem *idêntica*; *near-duplicates* documentados no BUSI podem persistir, e a ausência de IDs de paciente impede a divisão por paciente.
- **Defeitos do conjunto.** Permanecem imagens com marcadores, texto, Doppler e estruturas não mamárias (Pawlowska et al., 2023, 2024), não removidas neste estudo.
- **Origem monocêntrica e tamanho reduzido.** Fonte única e poucas centenas de imagens limitam a generalização; uma única partição treino/teste apresenta variância alta, recomendando validação cruzada.
- **Sensibilidade limitada em maligno.** A revocação de 0,516 na classe maligna é insuficiente para qualquer pretensão clínica e indica necessidade de mais dados e de tratamento do desbalanceamento.
- **Sem validação externa.** Não se avaliou a transferência para outros equipamentos/populações (por exemplo, o conjunto curado BrEaST (Pawlowska et al., 2024)).
- **Escopo não clínico.** O trabalho não constitui validação clínica nem evidência de utilidade diagnóstica; não é um dispositivo médico.

7 Conclusão e Trabalhos Futuros

Apresentou-se um *pipeline* reprodutível para detecção e classificação de lesões mamárias em ultrassonografia com YOLO11s, enfatizando o rigor metodológico: conversão de máscaras em caixas, tratamento das imagens normais como negativos, mitigação e discussão do vazamento de dados do BUSI e, sobretudo, um protocolo de avaliação *adequado a detectores*. O modelo alcançou mAP@50 de 0,709 no conjunto de teste cego, demonstrando a viabilidade da abordagem como prova de conceito, com desempenho honesto e comparável, ressalvadas as limitações de dados e a sensibilidade ainda limitada na classe maligna. Mais do que perseguir índices máximos, busca-se uma avaliação *honest*a e comparável, condição necessária para que ferramentas de CAD sejam úteis na prática.

Como direções futuras: (i) validação cruzada *k*-fold (com pré-processamento dentro de cada *fold*) para reduzir a variância das estimativas; (ii) deduplicação perceptual e uso de versões curadas do BUSI, além de validação externa em conjuntos independentes; (iii) tratamento do

desbalanceamento entre classes para melhorar a revocação em maligno; (iv) comparação entre variantes do YOLO (n/s/m) e contra uma linha de base de classificação; e (v) avaliação de versões com inferência sem NMS (Ultralytics, 2026).

8 Considerações Éticas e Regulatórias

Este trabalho é uma prova de conceito de pesquisa e não constitui um dispositivo médico, diagnóstico ou recomendação de conduta clínica. A saída do modelo (benigno ou maligno, com grau de confiança) deve ser entendida como achado sugestivo, em referência ao léxico BI-RADS, e está sempre sujeita à avaliação de profissional habilitado. Do ponto de vista regulatório, software que analisa imagem médica de ultrassom recai na categoria de dispositivo sob a FDA (EUA); no Brasil, a RDC nº 657/2022 da ANVISA regula *software as a medical device* por classe de risco, e protótipos de pesquisa não comercializados e sem uso em decisão clínica não são registráveis. Evidências recentes de IA em rastreamento mamário, como o ensaio MASAI (Läng et al., 2023), posicionam a IA como segundo leitor de apoio, e não como substituto do radiologista.

Disponibilidade de dados e código

O conjunto BUSI é público (Al-Dhabyani et al., 2020). Código, notebook de treinamento/avaliação e demonstração interativa estão em <https://github.com/junowoz/deteccao-lesoes-mama-yolo>. Os artefatos de resultados (`resultados_experimentais.json`, figuras e tabelas) são gerados pelo notebook.

Contribuições dos autores (CRediT)

Ambos os autores contribuíram igualmente para a concepção do estudo e a redação do manuscrito. **F. Ramirez Pereira Botero:** ideiação original, metodologia, validação, análise formal, revisão e edição. **J. J. Gouvêa Cardenas:** metodologia, *software*, investigação experimental, curadoria de dados e visualização.

Conflitos de interesse

Os autores declaram não haver conflitos de interesse.

Financiamento

Os autores não receberam financiamento específico para a realização deste trabalho.

Referências

- AL-DHABYANI, W.; GOMAA, M.; KHALED, H.; FAHMY, A. **Dataset of breast ultrasound images**. Data in Brief, v. 28, art. 104863, 2020. DOI: 10.1016/j.dib.2019.104863.
- ANAS, M.; HAQ, I. U.; HUSNAIN, G.; JAFFERY, S. A. F. **Advancing breast cancer detection: enhancing YOLOv5 network for accurate classification in mammogram images**. IEEE Access, v. 12, p. 16474–16488, 2024. DOI: 10.1109/ACCESS.2024.3358686.
- CAMPOS, A. A. L. *et al.* **Time to diagnosis and treatment for breast cancer in public and private health services**. Revista Gaúcha de Enfermagem, v. 43, e20210103, 2022. DOI: 10.1590/1983-1447.2022.20210103.en.

- INSTITUTO NACIONAL DE CÂNCER (INCA). **Estimativa 2023: incidência de câncer no Brasil**. Rio de Janeiro: INCA, 2022. Disponível em: <https://www.inca.gov.br/publicacoes/livros/estimativa-2023-incidencia-de-cancer-no-brasil>.
- INSTITUTO NACIONAL DE CÂNCER (INCA). **Controle do câncer de mama no Brasil: dados e números 2024**. Rio de Janeiro: INCA, 2024. Disponível em: <https://www.inca.gov.br/mama>.
- JABEEN, K. *et al.* **Breast cancer classification from ultrasound images using probability-based optimal deep learning feature fusion**. *Sensors*, v. 22, n. 3, art. 807, 2022. DOI: 10.3390/s22030807.
- JOCHER, G.; QIU, J. **Ultralytics YOLO11**. Software, versão 11.0.0, 2024. Disponível em: <https://github.com/ultralytics/ultralytics>.
- KHANAM, R.; HUSSAIN, M. **YOLOv11: an overview of the key architectural enhancements**. arXiv:2410.17725, 2024. DOI: 10.48550/arXiv.2410.17725.
- LÄNG, K. *et al.* **Artificial intelligence-supported screen reading versus standard double reading in the Mammography Screening with Artificial Intelligence trial (MASAI): interim safety analysis**. *The Lancet Oncology*, v. 24, n. 8, p. 936–944, 2023. DOI: 10.1016/S1470-2045(23)00298-X.
- MOHAMMED, A. D.; EKMEKCI, D. **Breast cancer diagnosis using YOLO-based multiscale parallel CNN and flattened threshold Swish**. *Applied Sciences*, v. 14, n. 7, art. 2680, 2024. DOI: 10.3390/app14072680.
- PAWLOWSKA, A.; KARWAT, P.; ZOLEK, N. **Letter to the editor. Re: “Dataset of breast ultrasound images”**. *Data in Brief*, v. 48, art. 109247, 2023. DOI: 10.1016/j.dib.2023.109247.
- PAWLOWSKA, A. *et al.* **A curated benchmark dataset for ultrasound based breast lesion analysis (BrEaST)**. *Scientific Data*, v. 11, 2024. DOI: 10.1038/s41597-024-02984-z.
- PIRES, S. R.; MEDEIROS, R. B.; SCHIABEL, H. **Banco de imagens mamográficas para treinamento na interpretação de imagens digitais**. *Radiologia Brasileira*, v. 37, n. 4, p. 239–244, 2004. DOI: 10.1590/S0100-39842004000400006.
- PRINZI, F.; INSALACO, M.; ORLANDO, A.; GAGLIO, S.; VITABILE, S. **A YOLO-based model for breast cancer detection in mammograms**. *Cognitive Computation*, v. 16, p. 107–120, 2024. DOI: 10.1007/s12559-023-10189-6.
- REDMON, J.; DIVVALA, S.; GIRSHICK, R.; FARHADI, A. **You Only Look Once: unified, real-time object detection**. In: *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016, p. 779–788. DOI: 10.1109/CVPR.2016.91.
- TIAN, Y.; YE, Q.; DOERMANN, D. **YOLOv12: attention-centric real-time object detectors**. arXiv:2502.12524, 2025. DOI: 10.48550/arXiv.2502.12524.
- ULTRALYTICS. **Ultralytics YOLO26 documentation**. 2025–2026. Disponível em: <https://docs.ultralytics.com/models/yolo26>.
- WURZEL, P.; MARTINS, M. O. **Classificação de imagens de mamografia com Machine Learning no auxílio de diagnósticos de câncer de mama**. *Disciplinarum Scientia: Naturais e Tecnológicas*, v. 23, n. 2, p. 1–17, 2022. DOI: 10.37779/nt.v23i2.4140.
- YAP, M. H. *et al.* **Automated breast ultrasound lesions detection using convolutional neural networks**. *IEEE Journal of Biomedical and Health Informatics*, v. 22, n. 4, p. 1218–1226, 2018. DOI: 10.1109/JBHI.2017.2731873.